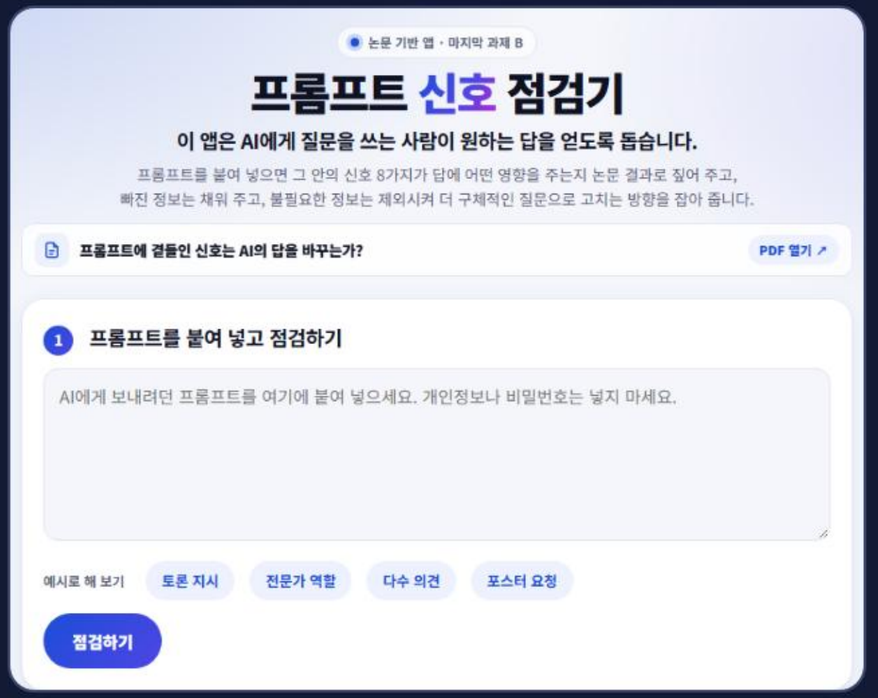
HW13 · 나의 앱 프로젝트 최종 발표

프롬프트 신호 점검기

AI에게 곁들이는 말보다, 필요한 건 정보였을까?

논문의 가설을 앱으로 만들고, 그 앱의 가설을 숫자로 검증했다



gamedh823-cmd.github.io/T13

1 · 출발점: 지난 논문 (HW10)

AI는 말도 안 되게 똑똑할까?

그렇다면 “전문가처럼”, “단계별로” 같은 말을 곁들이면 답이 더 좋아질까?
세 AI에 같은 질문을 신호 있이/없이 던져 비교했다.

전문가 역할 | 토론 지시 | 단계별 풀이 | 다수 의견

ChatGPT · Gemini · Claude



1 · 논문이 찾은 것

신호는 답의 모양만 바꿨다

정답 수

그대로

Claude·Gemini 10/10, ChatGPT도 한 문제 차이

답 길이

+2~19%

말을 붙이면 답이 길어졌다 (ChatGPT 19, Claude 10, Gemini 2)

"전문가로서" 말투

0 / 30

세 AI 모두 한 번도 쓰지 않았다

단, 정답이 하나인 계산 문제였고 점수가 이미 높았다 → 열린 질문은 못 봤다

2 · 앱을 만든 이유

논문에서 앱의 가설까지

논문의 가설

곁들인 신호가 답을 바꾼다

→

논문의 결과

모양(길이)만 바뀌었다

→

앱의 가설

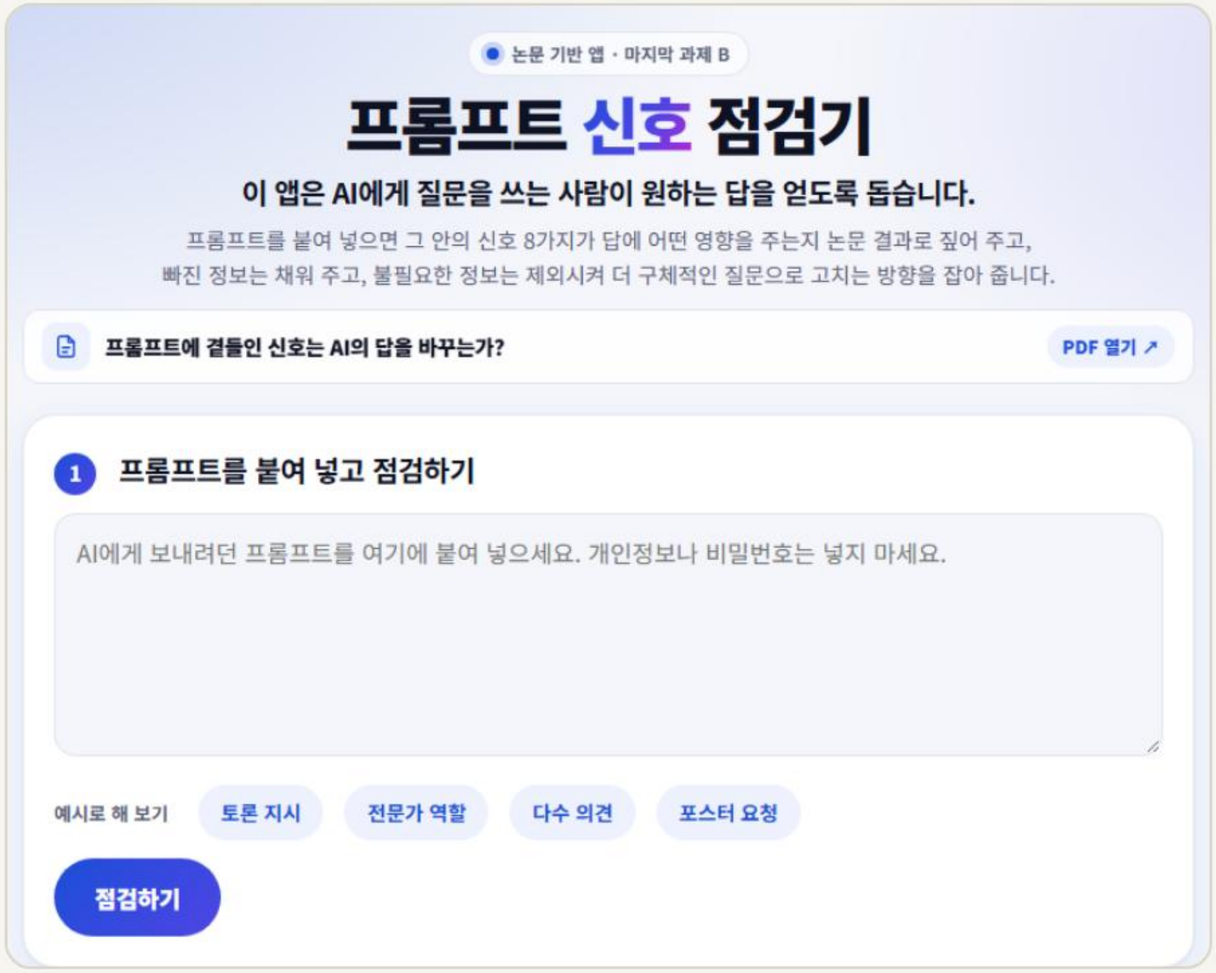
정보가 원하는 답을 만든다

→

검증

열린 질문 24개로 실험

신호를 “붙이라”가 아니라 정보를 “채우라”고 안내하는 앱이어야 하는지, 숫자로 확인한다



3 · 앱이 하는 일

붙여 넣으면 빠진 정보를 짚어 준다

1. 프롬프트를 붙여 넣고 점검
2. 들어 있는 신호와 논문 결과 확인
3. AI가 고친 프롬프트 받기

로그인 없음 · 입력은 저장하지 않음 · 첫 화면에서 스크롤 없이 바로 입력



3 · 신호 점검 화면

“너는 20년 경력 전문가야. 단계별로…”를 넣으면

① **신호 8가지** 중 몇 개인지 칩으로

② **찾은 표현**과 **확신도(%)**

③ **논문 결과**를 바로 아래에 연결

진한 칩 4개는 논문이 실험한 신호, 연한 칩 4개는 선행 연구에서 가져온 신호

3 · 신호 판정의 정확도

문장 2000개로 학습, F1 82% → 97%

합성 1432 · 직접 쓴 291 · 어려운 문장 277
학습 1634 / 검증 366

기준	문장 수	정밀도	재현율	F1
개발용 라벨 · 예전 규칙(비교용)	96	84%	80%	82%
개발용 라벨 · 학습 모델(지금 앱)	96	100%	94%	97%
처음 보는 표현(합성)	253	97%	86%	91%
직접 쓴 새 말투	113	95%	83%	89%
실제 사용 문장	6	100%	100%	100%
보류용 라벨 (모델 수정 뒤 한 번만 쟀음)	20	93%	93%	93%

떼어 둔 보류용 20문장은 모델 수정을 마친 뒤 한 번만 쟀다 (F1 93%, 문장이 적어 참고용)

개발 점수는 실제보다 높을 수 있다. 신고로 들어온 오판은 평가 세트에 넣고 비슷한 문장으로 보강했다

3 · 앱이 지키는 두 가지 약속

없는 신호를 만들지 않고, 없는 정보를 지어내지 않는다

8가지 신호 중 0가지가 이 프롬프트에 있어요 (약한 신호 1가지)

- 토론 지시
- 전문가 역할
- 다수 의견
- △ 이미지 요청 구체성
- 풀이 과정 요구
- 예시 제시
- 내 의견 먼저
- 열린 추천 요청

진한 칸은 이번 논문이 직접 실험한 신호 4가지, 옅은 칸은 선행 연구에서 가져온 신호 4가지입니다. △는 확률이 낮아 확정하지 않은 약한 신호예요(vague 35%).

입력하신 “동네 카페 오픈 홍보 문구 써줘”에는 위 8가지 신호가 없어서, 논문이 비교한 기준(신호 없음) 조건과 같아요. 이 문장처럼 곁들인 말 없이 사실이나 정보를 묻는 질문은 보통 신호가 없어요. 신호가 없는 건 나쁜 게 아니라 “곁들인 말 때문에 답이 달라질 일이 없다”는 뜻이에요. 위의 예시 버튼으로 각 신호가 어떻게 잡히는지 볼 수 있어요.

약속 1. 신호가 없으면 없다고 말하고, 입력 문장을 그대로 인용한다

약속 2. AI 제안

원문의 의도를 바꾸지 않는다

모르는 예산·분량은 **[빈칸]**으로 남긴다

AI가 실패하면 규칙 제안만 보인다

3 · 피드백을 받고 바꾼 것

지적이 앱을 바꿨다

받은 지적	바꾼 것
버튼이 안 눌리고 디자인이 별로	파스텔 톤, 큰 버튼
스크롤해야 입력창이 보임	첫 화면에서 바로 점검
“~하지 마”도 신호로 잡음 (친구)	부정 표현 처리, 어려운 문장 학습
“저메추좀”이 판정되지 않음	실제 문장을 평가 세트에 추가
정밀도 1.00이 말이 되나	건수와 한계를 함께 공개
AI가 없는 설정을 지어냄	[빈칸] 규칙 추가

4 · 앱의 가설을 실험하다

같은 질문을 세 가지로 물어 비교했다

A 원문

질문 그대로

B 정보 추가

원문 + 육하원칙 6줄
(누가·언제·어디서·무엇을·왜·어떻게)

C 신호만 (대조군)

원문 + 전문가 역할·토론·단계별·다수 의견
새 정보는 없음, B와 비슷한 길이

질문 24개
추천·기획·글쓰기·조언 각 6

→

답 144개
질문 × 3조건 × 2회

→

블라인드 채점
다른 AI, 조건 가림

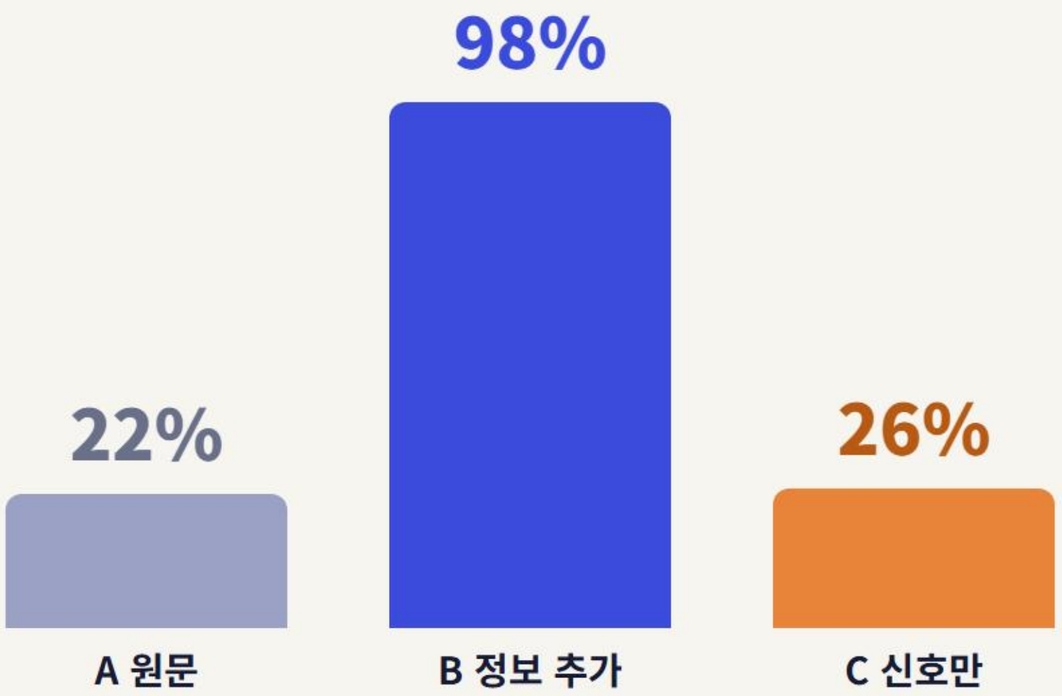
→

통계
95% 구간, 부호검정

체크리스트 5개는 답을 보기 전에 정해 두었다

4 · 결과: 사용자 의도를 충족한 답의 비율

정보를 넣으면 22%에서 98%로



B − A +76.7%p
95% 구간 [66.7, 85.8] · 24개 질문 모두 개선 · p<0.001

C − A +4.6%p
95% 구간 [−2.1, 11.3]이 0을 포함 → 차이 없음

답 길이 +94% (C)
1234자 → 2397자. 신호는 길이만 늘렸다

4 · 앱 맨 아래에 그대로 공개한 결과

질문 유형별로도 B가 가장 높았다

조건	체크리스트 충족률	의도 근접 점수(1~5)	답변 길이(자)	프롬프트 길이(자)
A 원문	22%	1.42	1234	9
B 육하원칙 정보	98%	4.92	1560	182
C 논문의 신호만	26%	1.44	2397	149



4 · 그래서 두 가설은

신호는 모양만, 정보는 답을 바꿨다

논문의 가설: 신호가 답을 바꾼다

모양만 바뀌었다

22% → 26%는 차이가 없고 답만 94% 길어졌다. 논문의 결론은 뒤집히지 않았다.

앱의 가설: 정보가 원하는 답을 만든다

이 실험에서 지지됐다

22% → 98%. 그래서 앱은 신호를 붙이라 하지 않고 빠진 정보를 채우라고 안내한다.

AI의 똑똑함은 우리가 건넨 정보만큼 쓰인다

4 · 이 결과가 말하지 못하는 것

98%를 그대로 믿으면 안 되는 이유

B에 유리한 구조

체크리스트가 사용자 정보에서 나왔다. 의미는 C와의 차이에 있다.

앱 효과는 안 쟀다

사용자가 정보를 직접 채우는지는 이 실험에 없다.

의도는 가상 상황

실제 사용자의 의도와 다를 수 있다.

채점은 Gemini

글자로 확인되는 24개 중 23개 일치. 사람 평가와의 일치는 미확인.

질문 24개, 한 AI 계열

다른 AI로 일반화하기 어렵다.

신호 라벨

라벨 116개는 AI 초안이고, 떼어 둔 20개는 아직 재지 않았다.

5 · AI와 나의 판단

AI는 만들고, 나는 방향을 정했다

AI가 한 일

- 질문 24개와 체크리스트 초안
- 실험·채점·집계 코드, 통계
- 앱 개선, 보고서, 라벨 초안 116개

내가 판단한 일

- 열린 질문에서 정보의 효과를 수치로 검증하겠다는 방향
- “모양만 바뀌면 앱의 이유가 뭐냐”는 문제 제기
- “정밀도 1.00이 말이 되나”라는 과장 지적
- 속도 우선 결정, API 키 직접 설정

AI 제안을 따르지 않은 일은 이번 구간에 없다 (실험 설계와 조건 C 추가는 AI가 제안했고 그대로 따랐다)

6 · 다음에 할 일

증명한 것과 못 한 것을 나눠 이어 간다

1. 동료 블라인드 평가로 채점 검증
2. 사용자가 정보를 채우는지 실험
3. 육하원칙 중 가장 중요한 칸 찾기
4. 다른 AI로 반복, 라벨 직접 검토

AI의 한계가 보여도 AI는 기하급수적으로 발전한다. 이 점검도 계속된다.

직접 써 보기

앱 (로그인 없음)

gamedh823-cmd.github.io/T13

소스·실험 코드·결과

github.com/gamedh823-cmd/T13